

**Прогноз
удовлетворённости
клиента для маркетплейса
Olist**
Capstone DataGroup



Дана Токтаргалиева
<https://github.com/danatoktargaliyeva/olist>

Цель проекта

Вопрос исследования:

Можно ли предсказать, что клиент поставит низкую оценку (1–2 звезды), ещё до того, как он её оставил — основываясь только на данных, известных в момент доставки заказа (тип товара, сумма, способ оплаты, продавец, сроки доставки)?

Каждая негативная оценка это:

- репутационный риск для продавца и площадки
- потерянный повторный клиент
- сигнал о проблеме в логистике или качестве, который бизнес видит только постфактум

Задача - вмешаться до плохого отзыва



План работы

9 CSV файлов Olist

orders

order_items

order_payments

order_reviews

customers

products

sellers

geolocation

category_translation

SQL Database **olist.db**


features

95 823 заказа

10 признаков:

delivery_days, delivery_vs_estimate, items_count, sellers_count, total_price, avg_item_price, total_freight, payment_types_count, total_payment, avg_seller_score

Таргет: оценка 1–2 = плохой отзыв





12.8%

заказов получили 1–2 ★ (12 269 из 95 823)*

Дисбаланс 87/13: accuracy бесполезна,
оцениваем ROC-AUC, precision, recall, F1


**Оценка 3 обычно отражает нейтральный опыт, поэтому была исключена из «плохого отзыва». Оценки 1–2 это чёткий сигнал недовольства, на который бизнесу стоит реагировать в первую очередь.*

Сроки доставки




Вывод: при 1 ★ доставка почти вдвое дольше, чем при 5 ★, а запас до обещанной даты вдвое меньше (выше шанс опоздать).


Другие факторы



«Недовольные» заказы немного дороже (~99 против ~85 BRL), но разница около 15%. Слабый фактор.



Рейтинг продавца растёт вместе с оценкой: от 3.85 до 4.1.




Чем больше товаров, тем ниже оценка: 1.33 при 1 ★ против 1.11 при 5 ★. Сложнее логистика — выше риск.

Вывод: все три фактора связаны с оценкой гораздо слабее, чем сроки доставки. Недовольство клиентов определяет прежде всего логистика.

Модели: Random Forest vs Logistic Regression


Тестовая выборка (20%), класс «плохой отзыв»



Выбор: Random Forest

- Стратифицированный split 80/20, class_weight = balanced, 10 признаков
- Выше ROC-AUC (0.79) и F1 (0.45) — лучший баланс точности и полноты
- LR ловит больше плохих отзывов (recall 0.61), но с большим числом ложных тревог

Что влияет на плохую оценку



57%

Логистика

срок доставки и запас до
обещанной даты — больше
половины вклада

19%

Продавец

средний рейтинг продавца

<5%

Деньги

сумма, цена и способ оплаты почти
не влияют

Рекомендации и ограничения

Ограничения

- Утечка данных: рейтинг продавца включает оценку текущего заказа — считать только по прошлым заказам
- ROC-AUC 0.79: часть причин (качество товара, общение с продавцом) в данных не отражена
- Дальше: сезонность, расстояние продавец–клиент, порог вероятности под бюджет компенсаций

Рекомендации

- Скорить каждый заказ при доставке: для группы риска — проактивное извинение, промокод или звонок поддержки
- Отслеживать заказы, где доставка дольше медианы или запас до обещанной даты сокращается
- Работать с продавцами с низким рейтингом: мониторинг отгрузки, приоритет в поддержке
- Масштаб: из 12 269 заказов с низкой оценкой модель заранее выявляет около 6 870 (56% recall) — это заказы, где можно успеть вмешаться до того, как клиент напишет жалобу.